

OULAD 조기 이탈 예측 - 데이터 탐색 리포트 (논의용)

데이터 감사·누수 검토·feature pipeline 완료. cohort 결정 완료. 이 문서는 모델링 직전 남은 결정 사항을 정리한 자료. 시각화는 [exploring_data_appendix.html](#) 참조.

1. 프로젝트 개요

- **목표:** week 5/7/10 (학기 시작 후 35/49/70일) 시점에 학생의 학업 위험 예측
- **데이터:** OULAD (Kaggle 버전), [student_info](#) 기준 32,593행 (학생 × 모듈 × 학기)
- **주요 feature 소스:** VLE 클릭 로그 10.6M행, 과제 제출 173.9K행

2. 핵심 용어

- **Cohort (코호트):** 각 cutoff 시점에 예측 대상이 되는 학생 집단. 이 프로젝트는 "현재 등록 중인 학생"(active-at-cutoff)을 cohort로 정의.
- **Cutoff:** 예측 기준 시점 (day 35/49/70). 이 시점 이후 정보는 feature에 못 들어감.
- **Leakage:** 예측 시점 이후 정보가 feature에 섞이는 것. [date_unregistration](#) 제외도 이 때문.
- **Target:** 예측할 정답 변수. 무엇을 "위험"으로 정의할지는 쟁점 ①.

3. 결정 완료 사항

✓ Cohort: Active-at-cutoff

[date_unregistration ≤ cutoff_day](#)인 학생을 각 cutoff에서 제외. 이미 떠난 학생은 활동도 거의 없어 "활동 없음 = 탈퇴"라는 자명한 패턴만 학습하게 되기 때문.

cutoff	원본	제외	cohort
week5 (day 35)	32,593	5,349	27,244
week7 (day 49)	32,593	5,817	26,776
week10 (day 70)	32,593	6,524	26,069

"활동 없음 → 탈퇴" 비율: 적용 전 82.9% → 후 20.4% (week5 기준).

생성 파일: [features_week{5,7,10}_cohort.csv](#)

4. Cohort 적용 후 데이터 특성

결과별 분포 (cohort 내)

결과	week5	week7	week10
Pass	12,361	12,361	12,361
Fail	7,044	7,044	7,044
Withdrawn	4,815	4,347	3,640
Distinction	3,024	3,024	3,024

신호 분포

- VLE는 week5에 거의 모두 시작, 과제 제출은 후반 cutoff에서 더 풍부 → 후반 cutoff일수록 assessment feature 비중 ↑
- VLE 활동 0인 학생: week5에 791명, week10에 529명

주요 결측 (week5 cohort 기준)

컬럼	결측	의미
<code>weighted_score</code>	6,413	가중치 있는 과제 미제출
<code>mean/min/max_score</code>	4,662	점수 받은 제출 없음
activity date 계열	791	VLE 활동 없음
<code>imd_band</code>	1,022	사회경제지표 원본 결측

핵심 판단: 점수·활동 결측은 "제출/활동 안 함"이라는 정보 그 자체 → 평균 imputation은 정보 왜곡.

5. 컬럼 카탈로그 (전체 70개, week10 기준)

✖ Predictor 사용 금지

순수 식별자 (1개)

- `id_student` — 학생 개인 ID, predictor 금지

Target & analysis only (2개)

- `final_result` (4-class label)

- `target_withdrawn` (현재 binary target)
- → `y`로만 사용, `x` 절대 금지

✅ 안전한 Predictor 후보

Course/Presentation metadata (2개) — base key의 일부이지만 categorical predictor로 사용 가능

- `code_module`, `code_presentation` — one-hot 또는 target encoding 권장
- `code_module`은 §04 분석에서 강한 신호 확인 (GGG 7.7% → CCC 27.6%)

Static demographic (8개) — 등록 시점 정보, 어느 cutoff에서도 안전

- `gender`, `region`, `highest_education`, `imd_band`, `age_band`
- `num_of_prev_attempts`, `studied_credits`, `disability`

VLE 종합 활동 (9개) — 모든 cutoff 필터됨

- `total_click_until_cutoff_sum_strategy` 또는 `_max_strategy` (쟁점 ②에서 택1)
- `active_days_until_cutoff`, `used_site_count_until_cutoff`
- `first/last_activity_date_until_cutoff`, `days_since_last_activity_at_cutoff`
- `avg_click_per_active_day_*` (sum/max 각각)

⚠️ 조건부 (검토 후 사용)

Registration timing (2개)

- `date_registration`, `is_registered_before_start` — 결측 7명, 처리 정책 필요 (쟁점 ③)

Assessment summary (8개)

- `assessment_count_until_cutoff` — §04에서 매우 깨끗한 단조 신호 확인 ✅
- `mean/min/max_score_until_cutoff`, `scored_assessment_count_until_cutoff` — 점수 결측 처리 필요
- `submitted_late_count_until_cutoff` — `assessments.date` 결측 11개 의존 (쟁점 ⑤)
- `weighted_score_until_cutoff` — `assessments.weight` 사전 공지 가정 (쟁점 ⑤)
- `assessment_rows_missing_due_date_until_cutoff`

Activity_type별 클릭 (19 × 2 전략 = 38개) — 쟁점 ② 결정에 따라 한 전략만 사용

19개 activity: dataplus, dualpane, externalquiz, forumng, glossary, homepage, htmlactivity, oucollaborate, oucontent, ouilluminate, ouwiki, page, questionnaire, quiz, repeatactivity*, resource, sharedsubpage, subpage, url

*`repeatactivity`는 week10에만 존재 → 모델 코드에서 cutoff별 컬럼 차이 처리 필요

1차 baseline 권장 셋 (15~20개)

그룹	컬럼
모듈/회차	<code>code_module</code> , <code>code_presentation</code>
인구통계	static demographic 8개
등록	<code>is_registered_before_start</code>
VLE 종합	<code>total_click_*</code> (1개 전략), <code>active_days_until_cutoff</code> , <code>days_since_last_activity_at_cutoff</code>
과제	<code>assessment_count_until_cutoff</code> , <code>mean_score_until_cutoff</code>

→ activity_type별 38개와 weighted_score 같은 conditional feature는 1차 후 점진 추가.

6. 남은 결정 사항

쟁점 ① Target 정의 — 가장 본질적인 결정

Cohort 내 분포

Target 정의	week5	week7	week10
A. Withdrawn만 (현재 <code>target_withdrawn</code>)	17.7%	16.2%	14.0%
B. Fail만	25.9%	26.3%	27.0%
C. Struggling (W+F)	43.5%	42.5%	41.0%

Cutoff 시점 행동 비교 (week5)

결과	n	평균 클릭	활성일	과제 제출	활동 0 비율
Distinction	3,024	633	23.4	1.22	0.6%
Pass	12,361	459	19.5	1.18	0.9%
Withdrawn	4,815	320	15.2	1.02	3.3%
Fail	7,044	248	12.0	0.95	7.1%

중요한 관찰: cutoff 시점 활동량 기준으로 Fail 학생도 Withdrawn 학생만큼, 또는 그보다 더 낮은 활동 패턴을 보임. 교수자 개입 관점에서는 Fail과 Withdrawn을 함께 "학업 위험군"으로 묶는 Target C도 검토할 가치가 있음.

대안과 장단점

대안	장점	단점
A. Withdrawn만	정의 단순, "이탈" 명확	Fail이 더 위험해 보이는데 놓침
B. Fail만	학업 실패에 집중	"Withdrawn 제외"가 부자연스러움
C. Struggling (W+F)	개입 대상 모두 포함, label 풍부	두 현상을 합치는 것에 대한 해석 필요
D. 4-class	정보 손실 없음	평가·운영 복잡

- 추천 논점: 누구를 위한 모델인가?
- 교수 개입 대상 찾기 → C (struggling)
 - 휴학 상담/리텐션 → A (Withdrawn)

⚠ **주의 1:** Target C 선택 시 프로젝트는 "조기 이탈 예측"이 아니라 ***조기 학업 위험군 예측***이 됨. 제목·문서에서 명확히 해야 함.

⚠ **주의 2:** 현재 cohort CSV의 `target_withdrawn`은 Withdrawn만 positive로 정의된 컬럼. Target C 선택 시 **새 컬럼을 만들어야 함:**

```
python
df["target_struggling"] = df["final_result"].isin(["Withdrawn", "Fail"]).astype(int)
```

쟁점 ② VLE 중복 처리

`student_vle` 키 중복이 exact duplicate 제거 후에도 1.4M행 남음. 같은 키의 `sum_click` 값이 모두 다름.

대안	장단점
A. sum (합산)	모든 활동 반영 vs 과대 집계 가능
B. max (최댓값)	보수적·안전 vs 진짜 다중 세션도 축소
C. 둘 다 만들어 비교	실증적 판단 vs 실험 복잡

이 중복 문제는 Kaggle 변환 오류가 아니라 **official OULAD에도 동일하게 확인된 원본 데이터 구조 또는 품질 이슈**임. 따라서 원인 파악이 아니라 sum/max 중 어떤 집계 전략을 쓸지의 결정 문제로 정리. sum vs max 차이는 cutoff별로 약 11%로 일정.

쟁점 ③ 결측치 처리

컬럼 그룹	권장 방향
점수·활동 결측	결측 플래그 + 0 채우기 또는 별도 처리
imd_band	"Unknown" 범주
assessments.date 11개	해당 과제만 due-date feature에서 제외

tree 계열은 일부 모델(XGBoost, LightGBM 등)이 NaN 처리를 지원하나, linear 계열은 imputation 필요. 최종 구현에서 모델별로 확인 필수.

쟁점 ④ Target 모호 케이스

Withdrawn인데 date_unregistration 결측인 93명은 cohort에 잔류함.

대안	장단점
A. cohort 유지	정의 일관성 vs 모호 케이스 포함
B. 별도 제외	깨끗 vs 93명 손실
C. sensitivity check	본 모델 후 별도 검증

절대 수가 작으니 일단 유지 후 최종 모델 단계에서 C로 검증 권장.

쟁점 ⑤ Conditional features

feature	검토 포인트
weighted_score_until_cutoff	가중치 사전 공지 여부 (보통 가능)
submitted_late_count	assessments.date 결측 처리에 의존
is_banked	cutoff 시점에 결정 완료 여부 확인
vle.week_from/to	82.4% 결측, 사용 어려움

1차 모델 후 점진적 추가 가능.

쟁점 ⑥ 참조 무결성 (해석 명확화)

`data_integrity_report.md`의 `right_only` 검사 결과를 정확히 해석하면:

항목	수	의미
VLE 활동 없는 base 학생	3,365	<code>student_info</code> 에는 있으나 <code>student_vle</code> 에 한 줄도 없음
사용 기록 없는 <code>assessment_id</code>	18	<code>assessments</code> 메타에는 정의되어 있으나 <code>student_assessment</code> 에 등장 안 함
사용 기록 없는 <code>site_id</code>	96	<code>vle</code> 메타에는 정의되어 있으나 <code>student_vle</code> 에 등장 안 함

`left_only`는 모두 0 → 로그에 있는데 메타에 없는 ID는 없음. 메타데이터 join에서 row 유실 문제는 없음.

→ 3,365명은 cohort에 그대로 남고 VLE feature가 0/결측으로 처리됨 (자동 제외 아님). 18·96개 미사용 ID는 join 시 자연스럽게 무관.

7. 결정 우선순위

- 1. ① Target 정의 — 모델 정체성을 결정
- 2. ② VLE 중복 — 가장 큰 feature 그룹에 영향
- 3. ③ 결측치 — 모델 입력 형태 확정
- 4. ④ Target 모호 케이스 — sensitivity check로 보완 가능
- 5. ⑤ Conditional features — 1차 모델 후 점진 추가
- 6. ⑥ 참조 무결성 — 추가 조치 불필요

제안: 1차 baseline은 보수적 셋(예: Target C + max 전략 + 결측 플래그)으로 만들고 다른 옵션과 비교.